



PROPAGATION ALGORITHM

๑๓๐๒๖๓

การเขียนโปรแกรมปัญญาประดิษฐ์

CONTENTS



- 1 Forward propagation
- 2 Backward propagation

FORWARD PROPAGATION

Algorithm มี Parameter w และ b ที่เป็นตัวแทนของข้อมูลเรียบร้อยแล้ว
กระบวนการ Forward propagation คือการนำข้อมูล x เข้ามาประมวลผลร่วมกับ Parameter เหล่านี้เป็นชั้นๆ จนได้คำตอบ



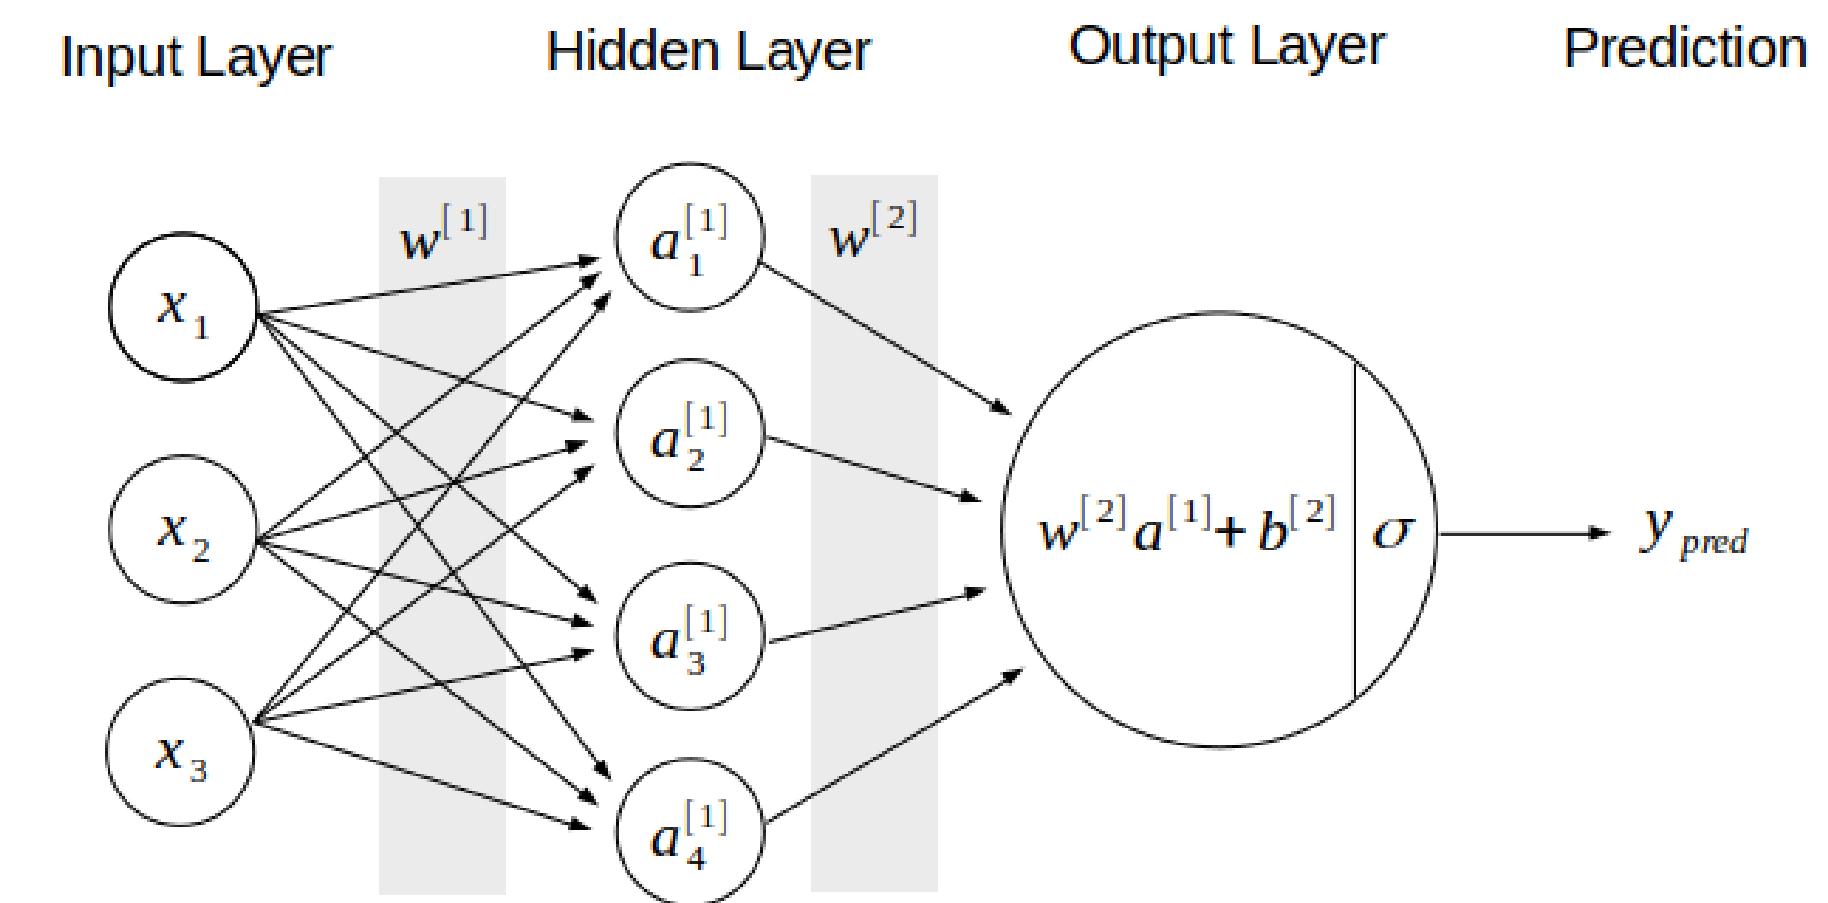
FORWARD PROPAGATION

ในตอนเริ่มต้น โมเดลจะยังไม่มี Parameter ที่ถูกต้อง เราจึงต้องสุ่มค่าเริ่มต้นของ Parameter ขึ้นมาก่อน เมื่อ Forward propagation ทำงานจบ 1 เที่ยว ก็จะเปรียบเทียบผลการพยากรณ์กับคำตอบที่รู้อยู่แล้ว จากนั้นโมเดลจะใช้กระบวนการตรงกันข้าม คือ Backward propagation ในการปรับค่า Parameter ให้สอดคล้องข้อมูลใน Train set มากขึ้น ทำอย่างนี้หลายๆ รอบจนกระทั่งได้ความแม่นยำของโมเดลตามที่ต้องการ



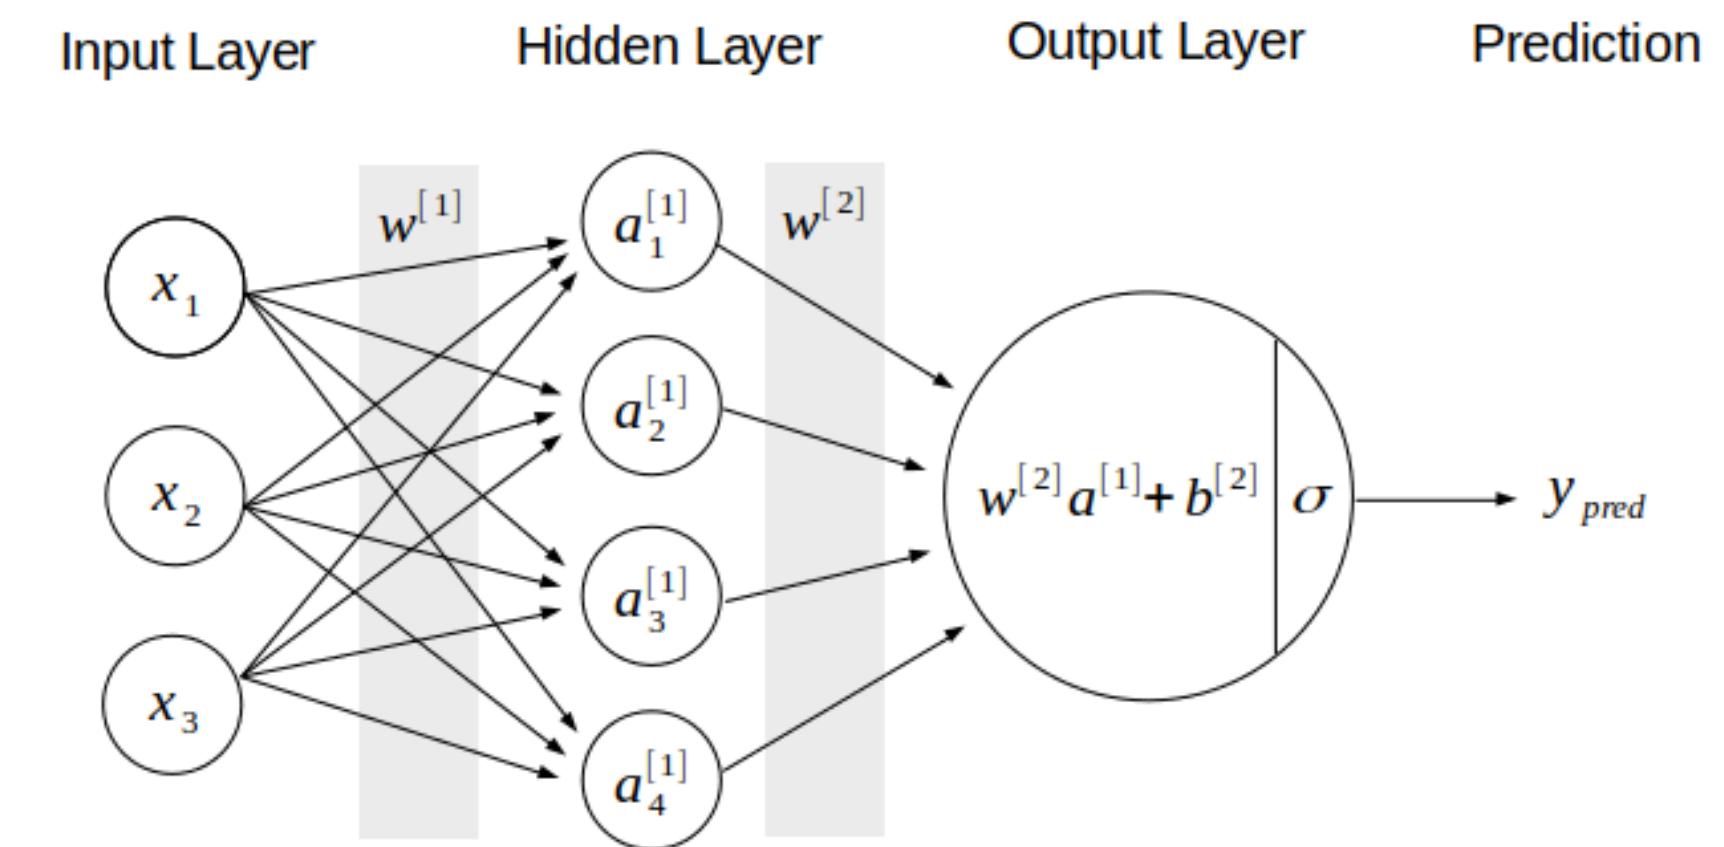
FORWARD PROPAGATION

Input layer คือข้อมูลขาเข้า ถ้าเป็นข้อมูลแบบมีโครงสร้าง x แต่ละตัวจะแทน **Feature** หรือคอลัมน์ของข้อมูล เช่น อายุ เพศ รายได้



FORWARD PROPAGATION

Hidden layer คือชั้นประมวลผลที่ซ่อนอยู่ ซึ่งมีได้หลายชั้น ใน **Hidden layer** แต่ละชั้นจะมีหน่วยประมวลผลที่เรียกว่า **Neuron**



FORWARD PROPAGATION

หน้าที่ของ **Neuron** แต่ละตัว คือการรับข้อมูล **Input** "ทุกตัว" จาก **Layer ก่อนหน้า** มาประมวลผลโดยใช้ **Linear function** ร่วมกับค่าน้ำหนัก **w** ของ **Input** แต่ละตัว ซึ่งให้ผล **z** และนำ **z** ไปคำนวณใน **Activation function g** ซึ่งอาจจะเป็น **Sigmoid, Tanh, หรือ RELU** ก็ได้ คำตอบที่ได้เรียกว่า **a** สังเกตว่า กระบวนการนี้คล้ายกับขั้นตอน **Classifier** ของ **ML algorithm**

$$z^{[1](i)} = W^{[1]}_x(i) + b^{[1]}$$

$$a^{[1](i)} = g(z^{[1](i)})$$

FORWARD PROPAGATION

- [1] ใน Brackets หมายถึงลำดับที่ของ Layer โดยนับ 1 ที่ Hidden layer แรก
- (i) ใน Parentheses หมายถึงลำดับรายการข้อมูลที่ i
- 1 ที่ห้อยด้านล่าง a คือลำดับที่ของ Neuron ใน Layer นั้นๆ
- นำสัญลักษณ์ทั้งหมดมารวมกัน ตัวอย่างเช่น $a[1](4)3$ หมายถึง Activation function ตัวที่ 3 ของ Layer ที่ 1

$$z^{[1]}(i) = W^{[1]}x^{(i)} + b^{[1]}$$

$$a^{[1]}(i) = g(z^{[1]}(i))$$

FORWARD PROPAGATION

สิ่งสำคัญที่ต้องรู้ในขั้นนี้ คือ **Hidden layer** สามารถมีได้หลายชั้น เช่นถ้าหากมีชั้นที่ 2 สมการที่ (1) ก็จะนำ $a[1]$ มาแทน x และใช้ W และ b ของ Layer ที่สอง โดย $[l]$ คือลำดับที่ของ Layer ชั้นนับ 1 ที่ **Hidden layer** ที่ 1

$$Z^{[1]} = W^{[1]} A^{[l-1]} + b^{[1]}$$

$$A^{[1]} = g(Z^{[1]})$$

FORWARD PROPAGATION

Output layer คือชั้นที่ประมวลผล

Activation a ทั้งหมดจากชั้นก่อนหน้า
โดยถือว่า $a[1]$ คือ **Input** ร่วมกับค่าหน้า
หน้า $W[2]$ ของ $a[1]$ ในชั้นก่อนหน้า (ไม่ใช่
ของ x ในชั้นแรก) ได้ผลเป็น $z[2]$ และนำ
 $z[2]$ ไปคำนวณใน **Activation function**
เช่น **Sigmoid function** ได้ผลเป็น $a[2]$

$$z^{[2](i)} = W^{[2]} a^{[1](i)} + b^{[2]}$$

$$a^{[2](i)} = \sigma(z^{[2](i)})$$

FORWARD PROPAGATION

ข้อมูลและตัวแปรแต่ละตัวใน Neural network มีหน้าตาอย่างไรในรูปแบบ Matrix และ Vector ข้อมูล Feature n0=4096 จำนวน m=10000 รายการ
มิติของ Matrix X คือ (n0,m)=
(4096,10000)

$$X = \begin{pmatrix} x_1^{(1)} & x_1^{(2)} & x_1^{(3)} & \dots & x_1^{(10000)} \\ x_2^{(1)} & x_2^{(2)} & x_2^{(3)} & \dots & x_2^{(10000)} \\ x_3^{(1)} & x_3^{(2)} & x_3^{(3)} & \dots & x_3^{(10000)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{4096}^{(1)} & x_{4096}^{(2)} & x_{4096}^{(3)} & \dots & x_{4096}^{(10000)} \end{pmatrix}$$

FORWARD PROPAGATION

ข้อมูลชุดนี้ใน Neural network ขนาด
Layer L=2 โดยมีจำนวน Neuron ใน
Layer แรก n1=4 Neuron ส่วน Layer ที่
สองเป็น Output layer ดังนั้นจึงมี
n2=1ค่า น้ำหนัก W[1] จะต้องคูณแบบ
Dot product กับ X ได้ ดังนั้นจึงมีมิติ
(n1,n0)=(4,4096)

$$W^{[1]} = \begin{pmatrix} w_1^{1} & w_1^{[1](2)} & w_1^{[1](3)} & \dots & w_1^{[1](4096)} \\ w_2^{1} & w_2^{[1](2)} & w_2^{[1](3)} & \dots & w_2^{[1](4096)} \\ w_3^{1} & w_3^{[1](2)} & w_3^{[1](3)} & \dots & w_3^{[1](4096)} \\ w_4^{1} & w_4^{[1](2)} & w_4^{[1](3)} & \dots & w_4^{[1](4096)} \end{pmatrix}$$

FORWARD PROPAGATION

Matrix Representation of Dot Product



$$\vec{A}^T = \begin{bmatrix} A_1 & A_2 & A_3 \end{bmatrix} \quad \vec{B} = \begin{bmatrix} B_1 \\ B_2 \\ B_3 \end{bmatrix}$$

$$\begin{bmatrix} A_1 & A_2 & A_3 \end{bmatrix} \begin{bmatrix} B_1 \\ B_2 \\ B_3 \end{bmatrix} = A_1 B_1 + A_2 B_2 + A_3 B_3 = \vec{A} \cdot \vec{B}$$

Dot Product

$$\begin{bmatrix} a & b \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = [ax + by]$$

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} ax + by \\ cx + dy \end{bmatrix}$$

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \cdot \begin{bmatrix} w & x \\ y & z \end{bmatrix} = \begin{bmatrix} aw + by & ax + bz \\ cw + dy & cx + dz \end{bmatrix}$$

FORWARD PROPAGATION

เมื่อ $W[1]X$ อยู่ในมิติ $(n1,n0) \times (n0,m) = (n1,m) = (4,10000)$ ดังนั้น $b[1]$ จึงจะต้องอยู่ในมิติ $(n1,1) = (4,1)$ จึงจะสามารถบวกเข้าไปสมการได้

$$b^{[1]} = \begin{pmatrix} b_1^{1} \\ b_2^{1} \\ b_3^{1} \\ b_4^{1} \end{pmatrix}$$

FORWARD PROPAGATION

ส่วน **A[1]** ก็มีมิติ (n_1, m) เหมือน **Z[1]**
เพราเป็นการนำ **Z[1]** มา **Apply**
activation function ด้วยการ
Broadcast พิงก์ชันเข้าไปใน **Matrix**

$$A^{[1]} = \begin{pmatrix} g(z_1^{1}) & g(z_1^{[1](2)}) & g(z_1^{[1](3)}) & \dots & g(z_1^{[1](10000)}) \\ g(z_2^{1}) & g(z_2^{[1](2)}) & g(z_2^{[1](3)}) & \dots & g(z_2^{[1](10000)}) \\ g(z_3^{1}) & g(z_3^{[1](2)}) & g(z_3^{[1](3)}) & \dots & g(z_3^{[1](10000)}) \\ g(z_4^{1}) & g(z_4^{[1](2)}) & g(z_4^{[1](3)}) & \dots & g(z_4^{[1](10000)}) \end{pmatrix}$$

FORWARD PROPAGATION

Prediction นำเอาผล Activation $a[2]$

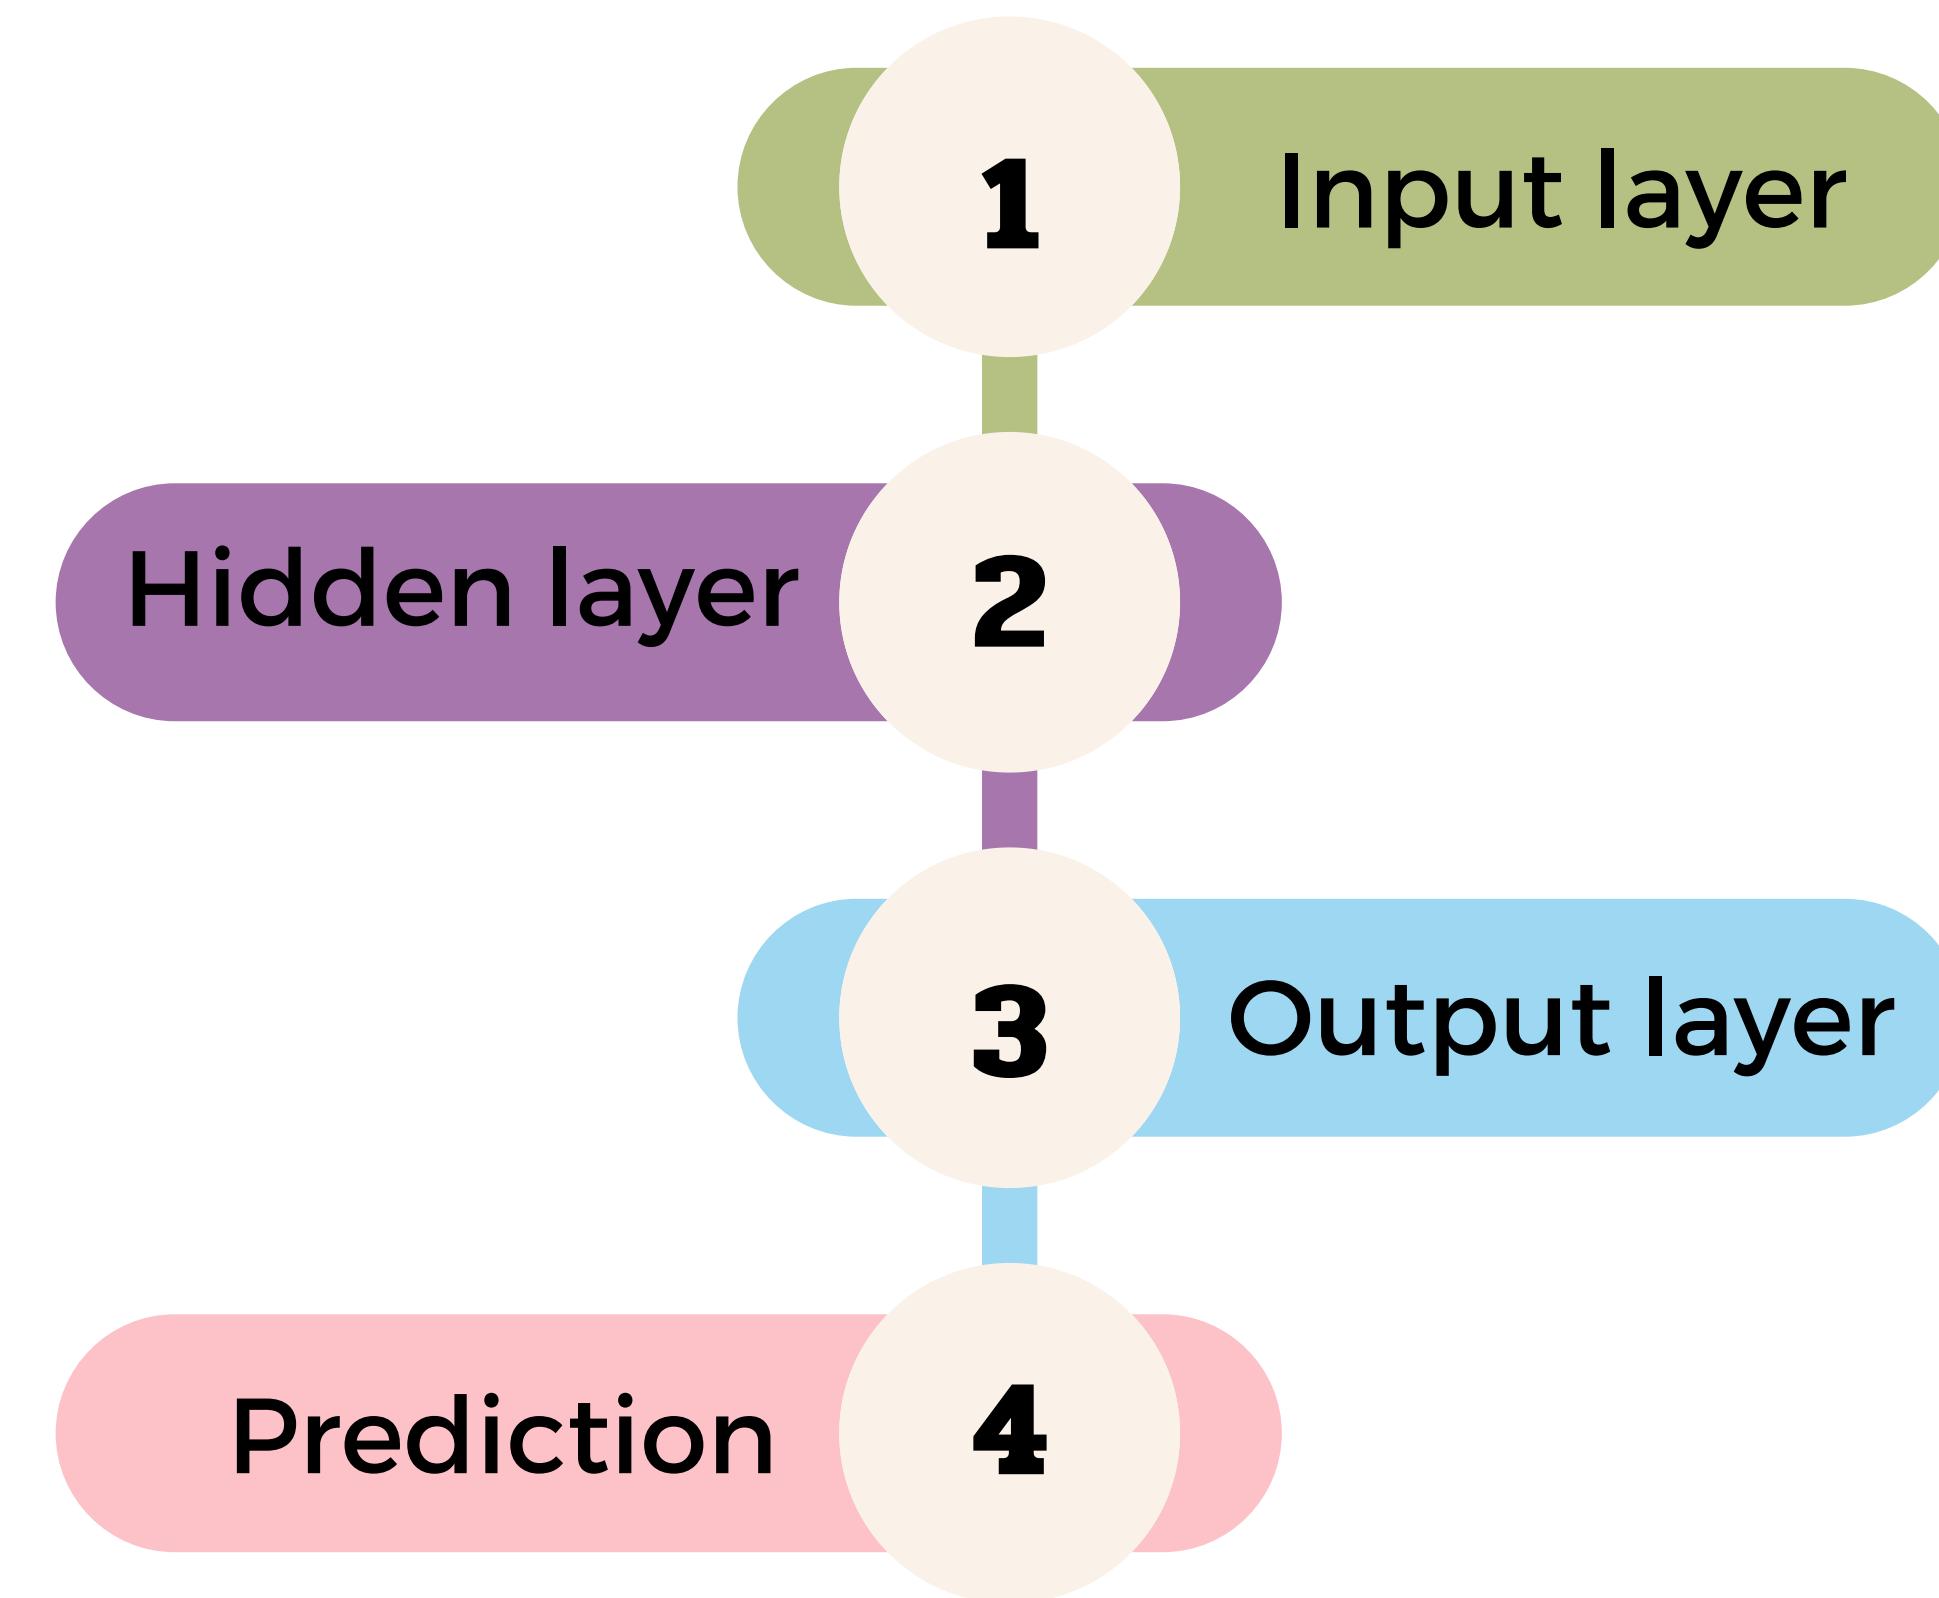
ของ Output layer มาตัดสินใจใน

Decision function เพื่อพยากรณ์ เป็น
เป็นสมการได้

$$y^{(i)} = a^{[2](i)}$$

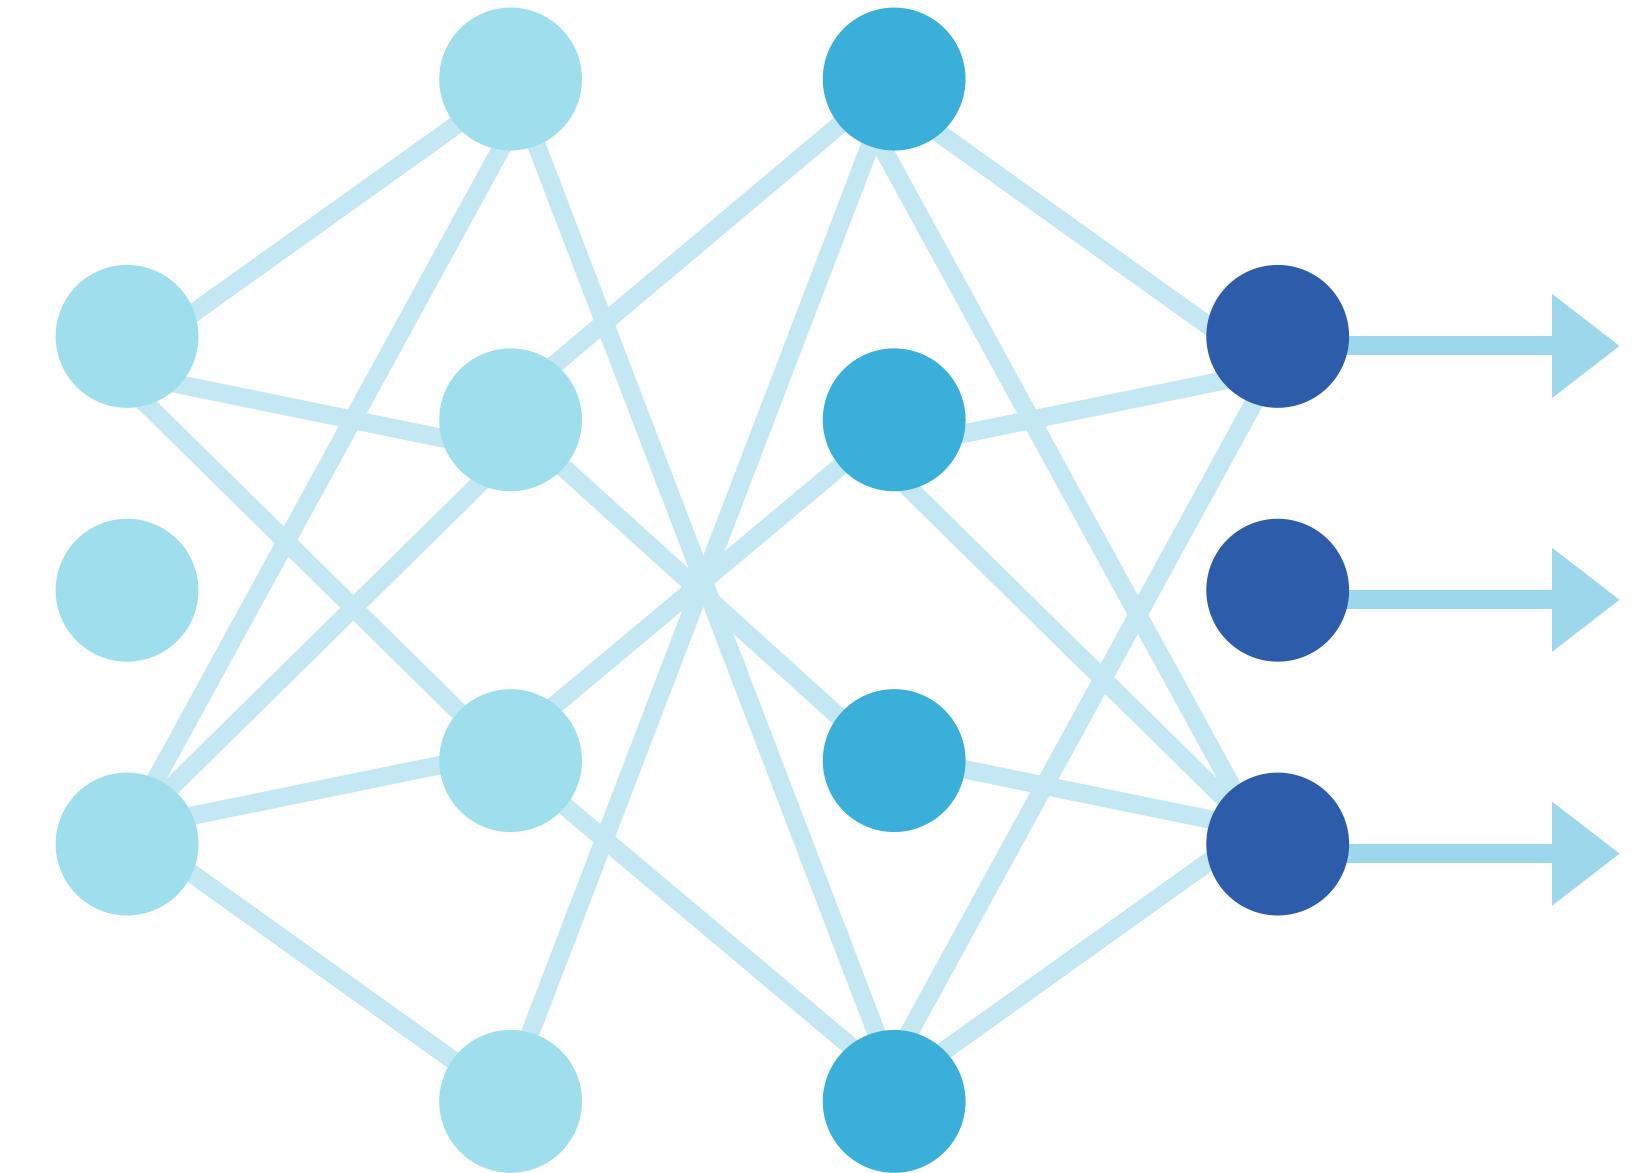
$$y_{\text{predict}}^{(i)} = \begin{cases} 1 & \text{if } a^{[2](i)} \geq 0.5 \\ 0 & \text{if } a^{[2](i)} < 0.5 \end{cases}$$

EXAMPLES OF ARTIFICIAL INTELLIGENCE



FORWARD PROPAGATION

กระบวนการทั้งหมดนี้ เรียกว่า **Forward propagation** ซึ่งจะลงด้วยการได้ค่าพยากรณ์ แต่แน่นอนว่าเมื่อยังไม่มี **Parameter w** และ **b** ที่ถูกต้อง ค่าที่พยากรณ์ได้ก็จะไม่ตรงกับความจริง ดังนั้น เราจะใช้กระบวนการ **Backward propagation** ในการปรับแต่ง **Parameter** ให้เป็นตัวแทนของข้อมูลได้เกียงตรงยิ่งขึ้น



BACKWARD PROPAGATION

Backward propagation คือส่วนที่ซับซ้อนและยากที่สุดของ Neural network algorithm



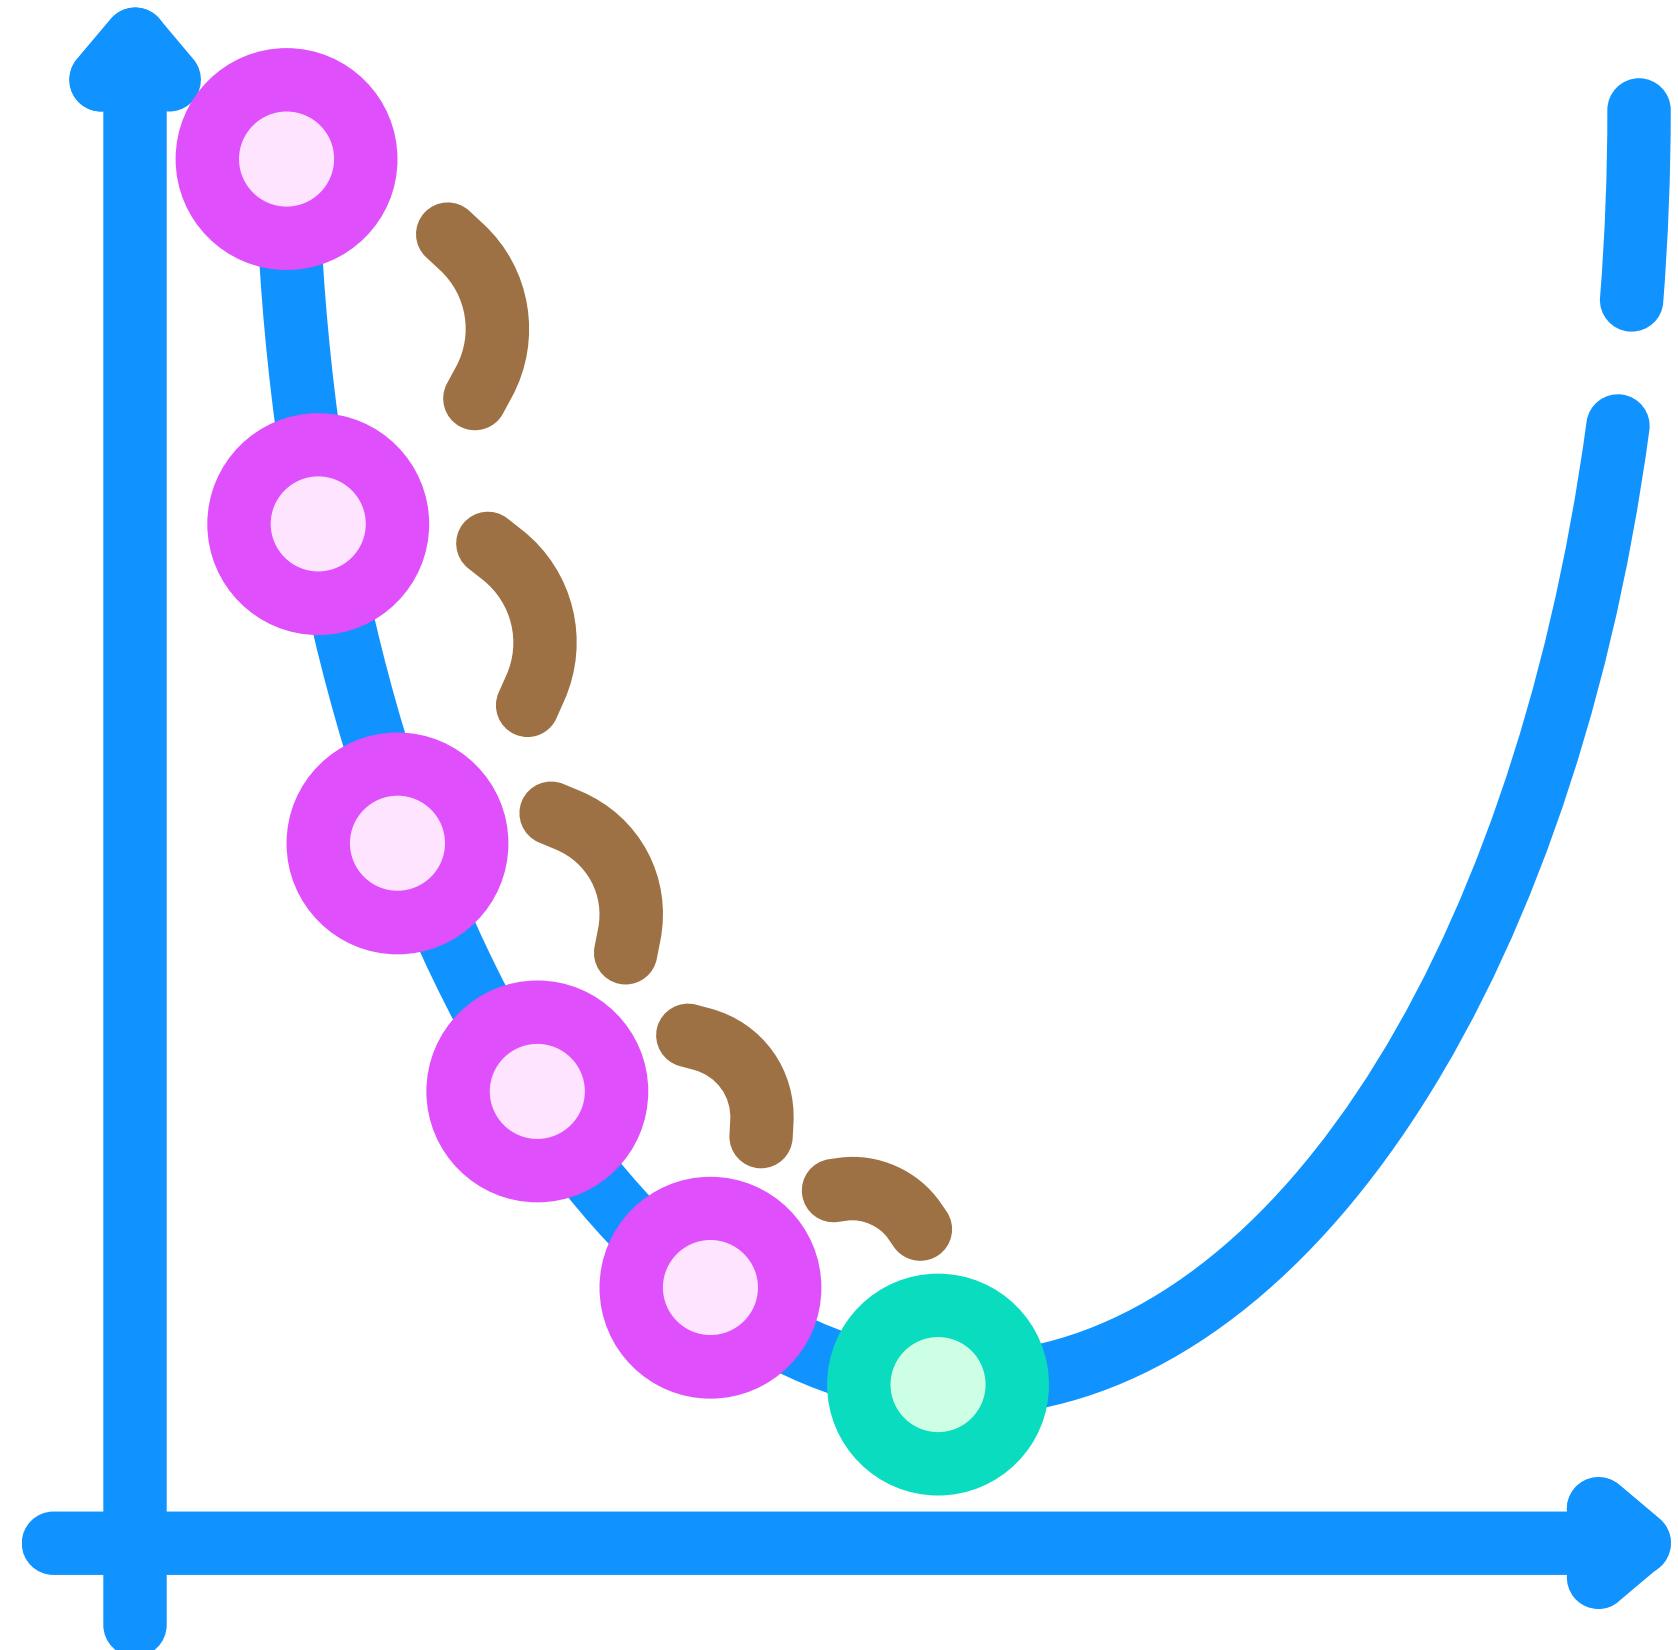
BACKWARD PROPAGATION

สามารถเขียนโค้ดของ Cost function โดยใช้ numpy ช่วย Vectorise เพื่อให้สามารถคำนวณ Cost function ของรายการข้อมูลทั้งหมดได้อย่างรวดเร็วโดยไม่ต้องใช้ For loop

```
logprobs = np.multiply(np.log(A2),Y) + np.multiply(np.log(1-A2),1-Y)  
cost = (-1/m)*np.sum(logprobs)
```

BACKWARD PROPAGATION

จะหาว่า Parameter ที่ทำให้ Cost function มีค่าต่ำที่สุด โดยใช้กระบวนการ Gradient descent ซึ่งมีหลักการคือ



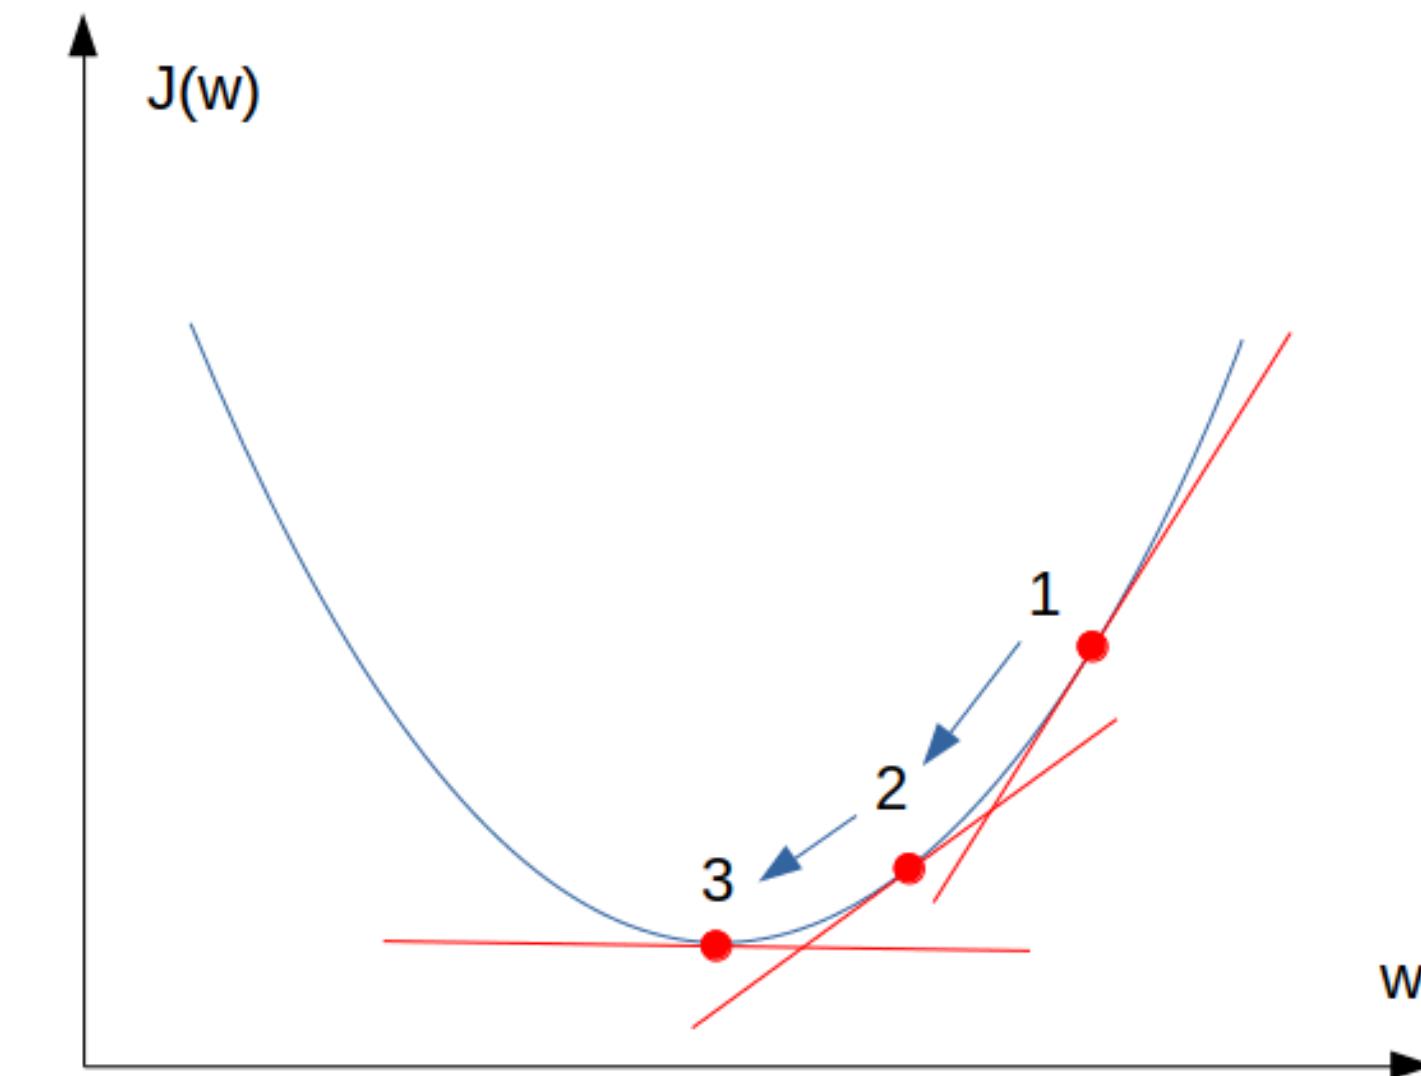
BACKWARD PROPAGATION

นำอนุพันธ์ที่ได้ไปลบออกจาก Parameter
นี้ โดยควบคุมความเร็วในการลบด้วย
Learning rate α และนำ Parameter
ใหม่ไปคำนวนใน Forward propagation
จะได้ Cost function ที่มีค่าลดลง ทำซ้ำขึ้น
ตอนนี้ไปเรื่อยๆ จน Cost function มีค่าต่ำ^{ที่สุดที่จะเป็นไปได้}

$$w := w - \alpha \frac{\partial}{\partial w} J(w)$$

BACKWARD PROPAGATION

เป็นการวนของกระบวนการ แต่ใน Neural network เราเมื่อ Parameter หลายตัวและหลายชั้น ดังนั้นเราจึงต้องใช้หลายสมการในการหาอนุพันธ์ของ Parameter แต่ละตัว



BACKWARD PROPAGATION

โดย Parameter ที่ต้องหาอนุพันธ์ คือ Parameter ที่ส่งผลต่อค่าพยากรณ์ ได้แก่:

- z ของแต่ละ Layer ไม่ได้เป็นตัวแปรที่ต้องการ Optimise แต่จำเป็นต้องหาอนุพันธ์เพื่อจะได้ใช้ Chain rule หาอนุพันธ์ของ w และ b ได้
- w ของแต่ละ Layer เพราะเป็น Coefficient ของ x
- b ของแต่ละ Layer เพราะเป็น Intercept ของ Linear function

$$z = wx + b$$

หาอนุพันธ์ของ z เช่น $dz[2]$ และ $dz[1]$ เพื่อเป็นอนุพันธ์ตั้งต้นให้หาอนุพันธ์ของ w และ b ได้ตามที่เขียนไว้

$$dz^{[2]} = a^{[2]} - y$$

$$dW^{[2]} = dz^{[2]} a^{[1]T}$$

$$db^{[2]} = dz^{[2]}$$

$$dz^{[1]} = W^{[2]T} dz^{[2]}$$

$$dW^{[1]} = dz^{[1]} x^T$$

$$db^{[1]} = dz^{[1]}$$

BACKWARD PROPAGATION

อนุพันธ์กั้ง 6 ตัว (สำหรับโนเดลความลึก 2 ชั้น ถ้า 3 ชั้นก็ต้องเพิ่มอีก 3 ตัว) เราจะจึงอ่าน
อนุพันธ์ของ w และ b ไปอัปเดตค่าตัวแปร กั้งสอง

$$W^{[1]} := W^{[1]} - \alpha(dW^{[1]})$$

$$b^{[1]} := b^{[1]} - \alpha(db^{[1]})$$

$$W^{[2]} := W^{[2]} - \alpha(dW^{[2]})$$

$$b^{[2]} := b^{[2]} - \alpha(db^{[2]})$$

BACKWARD PROPAGATION

แล้วนำตัวแปรที่อัปเดตแล้วไปคำนวณ Forward propagation ใน Epoch ใหม่ แล้วคิดอนุพันธ์ นำอนุพันธ์มาอัปเดตตัวแปร ทำอย่างนี้ซ้ำไปเรื่อยๆ จนถึงจุดที่ Cost function มีค่าต่ำที่สุด ก็จะได้โมเดลที่ฟิตกับ Train set ที่ดีที่สุดเท่าที่จะเป็นไปได้





การเพิ่ม NODE และ LAYER



งาน

- ให้เปรียบเทียบการทำงานโดยให้เพิ่ม layer เป็น 1,2,3 และ layer ละ 10,100,1000 node โดยเปรียบเทียบ
 - Accuracy
 - ประสิทธิภาพ
 - จำนวน epoch ดูว่า คู่กับต้องการ epochs น้อยกว่า ให้ถึงระดับ accuracy ที่กำหนด
 - ความเร็วใน ดูว่า คู่กับสามารถทำงานได้เร็วกว่า